



Van De Walle Bernard (B)
Francois Thibault (A)
Van Der Essen Frédéric (C)

INGI2132 : LANGAGES ET TRADUCTEURS

Rapport Final

Prof. B. Le Charlier



It is now possible with the HAPPY-) programming language!

Table des matières

1	Présentation de Happy :-)	6
1.1	Introduction	6
1.2	Grammaire de départ	6
1.3	Exemple de programme complet	8
2	L'analyseur Lexical	11
2.1	Entrée de l'analyseur lexical	11
2.2	Symboles terminaux de bases	12
2.3	Grammaire formelle	12
2.4	Représentation des symboles lexicaux	13
2.5	Spécification rigoureuse des méthodes publiques de l'analyseur lexical	14
2.6	principe d'implémentation	14
2.7	Tests de l'analyseur lexical	15
2.8	Test avec entrée valide	15
2.8.1	Tests avec entrée invalide	15
3	Vérificateur de grammaire WP	17
3.1	BNF Parser	17
3.2	Représentation Java de la grammaire et de ses éléments . . .	17
3.2.1	Term	17
3.2.2	CatList	18
3.2.3	Rule	18
3.3	Architecture	18
3.4	Test de symbole vide (<i>CheckLambda</i>)	18
3.5	Test de conflit de préférence (<i>CheckPrecedence</i>)	18
3.6	Preuve de l'algorithme	19
3.6.1	\doteq	19
3.6.2	\leq	20
3.6.3	$>$	20
3.7	Test de Suffixe	20
3.8	Test de Cycles	20
3.9	Spécifications des méthodes importantes	20

3.10	Test du vérificateur	22
3.11	Premier Test	22
3.12	Second Test	23
3.13	Troisième Test	23
4	Analyse syntaxique	25
4.1	Grammaire WP du langage	25
4.2	Problèmes rencontrés	25
4.3	Code de l'analyseur syntaxique	26
4.4	Traduction du programme en code interne	28
4.4.1	Création de l'arbre syntaxique du programme	28
4.5	traduction	29
4.6	traduction du code en code interne	32
5	Interpréteur	35
5.1	Implémentation	35
5.1.1	Changement de l'implémentation	36
5.1.2	Lien avec la sémantique opérationnelle	37
5.1.3	Test	37
6	Mode d'emploi du compilateur	38
6.1	Les erreurs	38
6.2	Les erreurs du vérificateur	38
6.3	Les erreurs du parser lexical	39
6.4	Les erreurs de l'analyseur syntaxique	39
6.5	Les erreurs du traducteur	39
6.6	Les erreurs de l'interpréteur	39

Introduction

Voici le rapport final de notre projet où il nous était demandé de réaliser un interpréteur avec comme contrainte l'utilisation d'une syntaxe WP.

Nous pensons avoir complété l'entièreté du projet. Il reste cependant un oubli au niveau du vérificateur de grammaire : Celui ci ne vérifie pas la présence de Symboles non terminaux intermédiaires inutiles. Et certaines parties du code utilisent des raccourcis douteux.

Il reste donc très certainement de nombreux bogues à découvrir.

Le rapport suit à la lettre le plan donné dans les consignes.

Chapitre 1

Présentation de Happy :-)

1.1 Introduction

La langage happy, appelé ainsi parce qu'il est très permissif au niveau des caractères permet dans les identifiants comporte de nombreuses autres particularités. Tout d'abord, le langage ressemble très fort au LISP où tout est atom ou liste. Mais contrairement au LISP, notre langage est impératif et orienté objet. Un programme est une liste de méthode, une méthode est une liste dont le premier élément est le mot réservé fun le second une list d'argument et le dernier une liste de commande. Même principe pour le while et le if. Dans ce langage tout est fonction, dans le sens que toute instruction renvoie une valeur, y compris les if et le while qui renvoient 0, une fonction qui n'a pas d'instruction return renvoie null, le write renvoie la valeur qu'elle vient d'imprimer etc...

Les conditions aurait aussi renvoyé une valeur si le langage SLIP dans lequel notre langage est traduit le permettait.

1.2 Grammaire de départ

Cette grammaire est la grammaire exhaustive du langage si on rajoute que les id peuvent être formé de tout les caractères UTF-16 sauf des caractères réservés et qu'ils ne doivent pas être égale à un mot réservé.

```
<Program> ::= ( <Prog_list> )  
<Prog_list> ::= <Meth_or_fun> | <Prog_list> <Meth_or_fun>  
<Meth_or_fun> ::= <Method> | <Function>  
  
<Function> := ( fun ( <Arglist> ) <Instr_list> )  
<Arglist> ::= id | id <Arglist>  
<Method> ::= ( <Method_int> ( <Arglist> ) <Instr_list> )
```

```

<Instr_list> ::= <Instr> | ( <Instr_list_np> )
<Instr_list_np> ::= <Instr> | <Instr> <Instr_list_np>
<Instr> ::= <Conditional> | <While_block> | <Call> | ( return <Expr> )

<Conditional> ::= ( if <Cond> <instr_list> <instr_list> )
<Conditional> ::= ( if <Cond> <instr_list> )
<While_block> ::= ( while <Cond> <Instr_list> )
<call> ::= <User_call> | <Method_call> | <Builtin_call>
<Builtin_call> ::= <Assignment> | <Read_call> | <Write_call> | <Arithmetic_call>
<Assignment> ::= ( set id <Expr> )
<Assignment> ::= ( set <Id_int> <Expr> ) | ( set <This_int> <Expr> )
<Read_call> ::= ( read )
<Write_call> ::= ( write <Expr> )
<Arithmetic_call> ::= <Binary> | <Unary>
<Binary> ::= ( <Bin_id> <Expr> <Expr> )
<Unary> ::= ( <Un_id> <Expr> )
<User_call> ::= ( id <Expr_list_np> ) | ( id )
<Expr_list_np> ::= <Expr> | <Expr> <Expr_list_np>
<Method_call> ::= ( <Id_id> <Expr_list_np> ) | ( <Id_id> )
<Method_call> ::= ( <Super_id> <Expr_list_np> ) | ( <Super_id> )
<Method_call> ::= ( <This_id> <Expr_list_np> ) | ( <This_id> )
<Expr> ::= number | null | true | false | this | id
<Expr> ::= <Id_int> | <This_int> | <Instr>
<Cond> ::= <Rel> | ( <Log_bin_op> <Cond> <Cond> )
<Cond> ::= ( <Log_un_op> <Cond> <Cond> )
<Rel> ::= ( <Rel_op> <Expr> <Expr> )
<Rel_op> ::= <= | >= | > | < | =
<Log_bin_op> ::= and | or
<Log_un_op> ::= !
<Bin_id> ::= + | - | * | / | %
<Un_id> ::= neg
<Id_int> ::= id . number
<This_int> ::= this . number
<Super_id> ::= super . id
<This_id> ::= this . id
<Id_id> ::= id . id
<Method_int> ::= method . number

```

Cette grammaire n'est pas wp, mais elle exprime très bien ce qui est syntaxiquement correcte dans ce que nous avons réellement implémenté.

Voici quelque bout de code permis par cette grammaire :

```

[Le while s'écrit comme ceci while (la condition) (les instruction a répéter)
ici la condition est 3 * i <= 9

```

On remarque aussi que sur ce bout de code on peut écrire la valeur de retour de set qui sera ici i_initial + 1 ou i_final]

```
(while (<= (* 3 i) 9) (write (set i (+ i 1))))
```

[Condition ici si i != 9]
 [Ensuite si vrai on exécute la première list d'instruction sinon la seconde]
 (if (! (= i 9)) (return true) (return false))
 [Ceci est équivalent à sauf que dans le cas deux on voit
 clairement les listes d'instructions]
 (if (! (= i 9)) ((return true)) ((return false)))

```
(fun (++ i) (return (+ i 1)))
```

```
(set i (++ i))
```

```
(set a (new 2))
```

1.3 Exemple de programme complet

Le premier programme imprime juste l'entier lu à la console.

```
(
  (fun (main)
    (write (read))
  )
)
```

Le programme suivant fait la somme de 1 à n pour 10 n

```
(
  [Programme fait la somme de 1 à n pour n qui va de 0 à 10]
  (fun (main) (
    (set i 0)
    (while (<= i 10)
      (
        (write (sum i))
        (set i (+ i 1))
      )
    ))
  ))

  (fun (sum n) (
    (if (= n 0)
      (return 0)
    )
  ))
)
```



```

    )
    (return (+ n (sum (- n 1))))
  ))
)

```

Le dernier programme fait la somme des éléments d'une pile et utilise la POO

```

(
  (fun (main) (
    (set s ( >> 4 ( >> 3 (>> 2 (# 1)))))
    (write (s.@))
    (write (s.->))
    (set s (>> 5 s))
    (Print s)
    (write (sum s))
  ))
  [crée une nouvelle pile avec a comme élément au sommet]
  (fun (# a) (
    (set b (new 2))
    (b.@= a)
    (b.->= null)
    (return b)
  ))

  [Push sur la stack]
  [a : l'élément à mettre sur la stack]
  [s : la stack]
  (fun (>> a s) (
    (set n (new 2))
    (n.->= s)
    (n.@= a)
    (return n)
  ))

  (fun (Print N) (
    (if (! (= N null)) (
      (write (N.@))
      (Print (N.->))
    )
    (write 0)
  )
  ))
)

```

```

(fun (sum N) (
  (if (! (= N null))
    (return (+ (N.@) (sum (N.->))))
    (return 0)
  )
))
[Accesseur pour l'élément contenu dans le noeud]
(method.2 (@) (return this.1))
((method.2 (@= a) (set this.1 a))
[Accesseur pour next]
(method.2 (->) (return this.2))
(method.2 (->= a) (set this.2 a))
)

```

Chapitre 2

L'analyseur Lexical

L'analyseur Lexical a pour fonction de sortir une suite de jetons concrets et de assez haut niveau, permettant de simplifier la tâche du vérificateur de grammaire. Plus concrètement, il s'agit dans un premier temps de transformer un fichier texte en une suite de caractères, et de les parser les uns après les autres. Chaque caractère donnera lieu à une action précise, par exemple les caractères spéciaux tel que les parenthèses et les points, etc... donnent lieu à un jeton entier. Les caractères qui ne sont pas des caractères spéciaux vont quand à eux remplir un buffer, qui sera rempli dès qu'un caractère spécial ou délimiteur sera rencontré. Une fois qu'un caractère de ce type est rencontré, on procédera à l'analyse de ce que contient le buffer, et selon le cas on en déterminera le type du jeton à donner.

2.1 Entrée de l'analyseur lexical

Il est important de préciser correctement ce que l'analyseur lexical doit prendre en entrée. Par soucis de facilité, nous avons décidé de nous restreindre aux caractères ascii 8 bits, et plus particulièrement, toutes les lettres (miniscule et majuscule), les chiffres, les opérateurs `*`, `+`, `/`, `-`, le symbole d'égalité, les parenthèses, les crochets (`[]`), et le point.

Ensuite il est nécessaire de définir les différents symboles de base que l'analyseur lexical va passer à l'analyseur syntaxique.

Voici donc les différentes catégories que l'analyseur lexical va sortir :

- `NUMBER` : Représente un ou plusieurs chiffres à la suite.
- `ID` : Représente une suite de caractères qui n'est pas un mot réservé.
- `UNARY_OP` : Représente un opérateur unaire, tel que l'opérateur `NOT` :!
- `BINARY_OP` : représente un opérateur binaire, tel l'opérateur `+`
- `*RESERVED_WORD*` : représente un mot réservé. En fait la catégorie sera le nom du mot réservé (d'où les étoiles), par exemple `FUN`

- **BEFORE_AFTER** : Représente ce qu’il y a avant et après un point. BEFORE et AFTER peuvent valoir : THIS, ID, INT

Finalement, il est de bon aloi de préciser que les espaces, les caractères de tabulations et de nouvelle ligne servent évidemment de caractère de séparation. Il n’est par contre pas nécessaire de placer un espace après une parenthèse par exemple, vu qu’il est assez naturel que ce qui suit sera le début d’un nouveau symbole.

Pour ce qui est des commentaires, nous avons introduit les symboles de crochet (`[]`). Tout ce qui se trouvera entre ces deux crochets (et les crochets eux-même compris), sera purement et simplement ignoré. Les commentaires peuvent donc s’étendre sur plusieurs lignes sans aucun problème.

Notre analyseur lexical ne renvoie plus de jetons à partir du moment où on atteint la fin du fichier. Il n’est pas nécessaire de terminer le fichier d’une manière particulière.

2.2 Symboles terminaux de bases

```
( ) <= >= > < = and or ! + - * / % neg id . number this super while
if set write read fun method null true false
```

C’est-à-dire tout les mots réservés qui se trouve dans le tableau *RESERVED_WORD* dans la classe *WordIdentifier.java* et tout le reste qui sont des id.

2.3 Grammaire formelle

```
<Program> ::= ( <Prog_list> )
<Prog_list> ::= <Meth_or_fun> | <Prog_list> <Meth_or_fun>
<Meth_or_fun> ::= <Method> | <Function>

<Function> := ( fun ( <Arglist> ) <Instr_list> )
<Arglist> ::= id | id <Arglist>
<Method> ::= ( <Method_int> ( <Arglist> ) <Instr_list> )

<Instr_list> ::= <Instr> | ( <Instr_list_np> )
<Instr_list_np> ::= <Instr> | <Instr> <Instr_list_np>
<Instr> ::= <Conditional> | <While_block> | <Call> | ( return <Expr> )

<Conditional> ::= ( if <Cond> <instr_list> <instr_list> )
<Conditional> ::= ( if <Cond> <instr_list> )
<While_block> ::= ( while <Cond> <Instr_list> )
<call> ::= <User_call> | <Method_call> | <Builtin_call>
<Builtin_call> ::= <Assignment> | <Read_call> | <Write_call> | <Arithmetic_call>
```

```

<Assignment> ::= ( set id <Expr> )
<Assignment> ::= ( set <Id_int> <Expr> ) | ( set <This_int> <Expr> )
<Read_call>  ::= ( read )
<Write_call> ::= ( write <Expr> )
<Arithmetic_call> ::= <Binary> | <Unary>
<Binary> ::= ( <Bin_id> <Expr> <Expr> )
<Unary>  ::= ( <Un_id> <Expr> )
<User_call> ::= ( id <Expr_list_np> ) | ( id )
<Expr_list_np> ::= <Expr> | <Expr> <Expr_list_np>
<Method_call>  ::= ( <Id_id> <Expr_list_np> ) | ( <Id_id> )
<Method_call>  ::= ( <Super_id> <Expr_list_np> ) | ( <Super_id> )
<Method_call>  ::= ( <This_id> <Expr_list_np> ) | ( <This_id> )
<Expr> ::= number | null | true | false | this | id
<Expr> ::= <Id_int> | <This_int> | <Instr>
<Cond> ::= <Rel> | ( <Log_bin_op> <Cond> <Cond> )
<Cond> ::= ( <Log_un_op> <Cond> <Cond> )
<Rel>  ::= ( <Rel_op> <Expr> <Expr> )
<Rel_op> ::= <= | >= | > | < | =
<Log_bin_op> ::= and | or
<Log_un_op>  ::= !
<Bin_id> ::= + | - | * | / | %
<Un_id>  ::= neg
<Id_int> ::= id . number
<This_int> ::= this . number
<Super_id> ::= super . id
<This_id>  ::= this . id
<Id_id>    ::= id . id
<Method_int> ::= method . number

```

2.4 Représentation des symboles lexicaux

Les Symboles lexicaux sont représenté à l'aide d'un objet de type `LexicalTerm`. Cet objet contient deux informations nécessaires. La première est la catégorie du symbole lexical, comme défini un peu plus haut. La seconde information est ce que contient concrètement le symbole lexical. Afin de clarifier cela, un petit exemple s'impose : Imaginons que l'analyseur lexical découvre un identifiant pour le mot "valeura" dans le fichier source. Dans ce cas, il créera un objet `LexicalTerm` contenant l'information suivante :

- TYPE : ID
- CONTENT : valeura

Dans le cas où maintenant le mot réservé `fun` est rencontré, l'objet `LexicalTerm` alors créé contiendra :

- TYPE : fun

– CONTENT : fun

2.5 Spécification rigoureuse des méthodes publiques de l'analyseur lexical

De manière concrète, l'analyseur lexical a été réalisé en implémentant l'interface `Iterator` et `Iterable`. Les méthodes publiques seront donc les méthodes propres à ces interfaces. Les méthodes utilisées par l'analyseur syntaxique sont donc :

La méthode `hasNext()`

```
/**
 * Returns true if the iteration has more elements.
 * (In other words, returns true if next() would
 * return an element rather than throwing an exception.)
 *
 * @return true if the iteration has more Term
 */
```

```
public boolean hasNext()
```

La méthode `next()`

```
/**
 * @return the next Term in the iteration
 * @throws NoSuchElementException if the iteration
has no more Term ( the end of the file is reached ).
 */
```

```
public Term next()
```

2.6 principe d'implémentation

Le principe d'implémentation est assez simple. Lorsque l'analyseur syntaxique appelle la méthode `next()`, l'analyseur lexical va lire les caractères suivants dans le fichier, jusqu'à pouvoir déterminer le prochain token.

Tant qu'un caractère de séparation n'est pas reconnu (un espace, une parenthèse,...), le caractère suivant est lu et placé dans un buffer. Lorsqu'un caractère de séparation est finalement rencontré, ce qui a été mis précédemment dans le buffer devient le prochain jeton, et le caractère de séparation deviendra celui d'après (sauf si il s'agit d'un espace, d'une nouvelle ligne, ou d'un caractère de tabulation).

2.7 Tests de l'analyseur lexical

Le but de ces tests est de voir les erreurs que renvoie l'analyseur lexical, et surtout de les comprendre.

2.8 Test avec entrée valide

Voici un petit programme qui est accepté par l'analyseur lexical, il n'affiche donc pas d'erreur, et le programme se déroule bien.

```
(  
  (fun (main) (  
    (set i 0)  
    (while (<= i 10) (  
      (write i)  
      (set i (+ i 1))  
    ))  
  ))  
)
```

2.8.1 Tests avec entrée invalide

T est d'un programme ayant une parenthèse fermante de trop (à la fin) :

```
(  
  (fun (main) (  
    (write 42)  
    ))  
)  
)
```

Sortie de l'analyseur lexical :

Too much)

L'analyseur lexical a donc bien détecté qu'il y a trop de parenthèses fermantes.

De même, si trop peu de parenthèses fermantes sont présente à la fin du fichier, l'analyseur lexical le détecte :

```
(  
  (fun (main) (  
    (write 42)  
  ))  
)
```

En sortie :

Unexpected end

Chapitre 3

Vérificateur de grammaire WP

3.1 BNF Parser

Le point de départ du vérificateur de grammaire est le parser BNF. Ce parser permet d'avoir sous une forme utilisable que nous détaillerons plus loin, les règles contenue dans le fichier. Le loader charge le fichier et le lit ligne par ligne. Chaque ligne contient l'ensemble des règles de production d'un non terminal, séparées par des barres. Les non terminaux sont entre '`|`', '`'`' et les terminaux sont entre guillemets. On peut échapper les guillemets ou les comparateurs par un backslash. Voici un exemple de fichier BNF accepté par le parseur :

```
__<E>_::=__<T>_|_'\\"'<T>_|_<T>_+'_<E>
__<T>_::=__<F>_|_<F>_*'_<T>
__<F>_::=__'\\"'
```

3.2 Représentation Java de la grammaire et de ses éléments

Toutes les classes représentant la grammaire et le parsing du bnf se trouvent dans le package *happy.parser.bnf*

3.2.1 Term

Le *Term* est la classe représentant le symboles terminaux et non terminaux de la syntaxe. *Term* représente aussi les terminaux renvoyés par l'analyseur lexical, et les noeuds des différents arbres syntaxiques. Cela permet d'éviter les conversions inutiles dans nos différents algorithmes. Sa méthode

qui nous concerne ici est `getType()` qui renvoie le nom du symbole (Number , Identifier , ...)

3.2.2 CatList

La *Catlist* est une liste de *Term* représentant une partie droite de production.

3.2.3 Rule

La *Rule* représente une règle de production. `getName()` renvoie le *Term* de la partie gauche, et `getOrList()` renvoie une liste de *Catlist*

3.3 Architecture

Le vérificateur de grammaire est implémenté comme une série de test statique correspondant aux conditions de Weak Precedence.

Tous ces tests prennent en paramètre la grammaire (une liste de "Rules")

Un test global - *CheckAll* - se charge de tester l'ensemble de ces tests. Toutes les classes et méthodes correspondantes se trouvent dans le package *happy.checker*

3.4 Test de symbole vide (*CheckLambda*)

Ce test s'assure qu'aucune règle n'a de production vide (lambda). Ce test parcourt simplement l'arbre de la définition grammaire et vérifie l'absence de terminaux lambda. Ce test vérifie aussi l'absence de Non terminaux n'ayant pas de règles de productions.

3.5 Test de conflit de préférence (*CheckPrecedence*)

Ce test vérifie qu'il n'y ait pas de conflit entre les précédence de symbole. Le seul conflit autorisé est entre \leq et \doteq qui donne la relation de précédence \leq

Pour faire cela, le test construit deux ensemble pour chaque non-terminal : First et Last. Ceux-ci permettront de déterminer très facilement les précédences par la suite. Soit un non terminal A : $First(A)$ contient l'ensemble des terminaux et non terminaux pouvant se trouver sur l'extrême gauche d'une production de A . $Last(A)$ contient l'ensemble des terminaux et non terminaux pouvant se trouver sur l'extrême droite d'une production de A .

Pour calculer Tous les First on utilise l'algorithme suivant :

1. Pour tout non terminal A de la grammaire : On identifie les règles correspondantes. Pour chacune d'entre elles on identifie si elles commencent par un terminal, et si c'est le cas on les ajoute à $First(A)$.
2. Pour tout non terminal A de la grammaire : On identifie les règles correspondantes, Pour chacune d'entre elles, on identifie si elles commencent par un non terminal B . Si c'est le cas on ajoute B et $First(B)$ à $First(A)$.
3. on répète l'étape précédente tant que les $First$ changent.

L'algorithme pour trouver les Last est identique à ceci près qu'on examine les cotés droits des règles.

Une fois que l'on a ces deux ensembles on peut calculer la table de précedence, grace à l'algorithme suivant :

1. On initialise tous les éléments de la table à '*Nothing*'
2. On identifie toutes les parties droites, et pour chacune d'entre elles on identifie tous les symboles côte à côte $..XY..$.
3. On ajoute $X \doteq Y$ dans la table.
4. Si X non terminal : Pour tout symbole s dans $Last(X)$, Pour tout terminal t dans $First(Y)$ on met $s > t$ dans la table. Si Y est terminal on met $s > Y$ dans la table.
5. Si Y non terminal : Pour tout symbole s dans $First(Y)$, on met $X < s$ dans la table.
6. Si à un moment on met une relation dans la table là ou précédemment il n'y avait pas '*Nothing*', on a un conflit. Les conflits impliquant $<$, \doteq et \leq sont résolus en insérant \leq dans la table. Les autres conflits sont marqués en tant que conflits et reportés.
7. Si il y a des conflits non résolus dans la table alors le Test échoue, la grammaire n'est pas valide Weak Precedence.

3.6 Preuve de l'algorithme

Cet algorithme nous vient de l'ouvrage *Parsing techniques - A practical guide* de Dick Grune et Ceriel J.H Jacobs

3.6.1 \doteq

Le critère utilisé par notre algorithme est identique à celui donné dans le cours.

3.6.2 \leq

Le cours donne le critère suivant : On a $X \leq Y$ si pour $A \Rightarrow \dots XC \dots$ on a $C \xRightarrow{+} Y \dots$. On constate que $First(C)$ donne tous les symboles terminaux et non terminaux tels que $C \xRightarrow{+} Y \dots$. le critère utilisé est donc identique.

3.6.3 $>$

Le cours donne le critère suivant : On a $X > y$ si pour $A \Rightarrow \dots BC \dots$ on a $B \xRightarrow{+} \dots X$ et $C \xRightarrow{*} y \dots$. $Last(B)$ donne tous les symboles tels que $B \xRightarrow{+} \dots X$ et $First(C)$ donne tous les symboles tels que $C \xRightarrow{+} Y \dots$. on en prend tous les terminaux et C lui même si terminal pour avoir l'ensemble tel que $C \xRightarrow{*} y \dots$. Le critère utilisé est donc identique.

3.7 Test de Suffixe

Ce test vérifie que les relations de suffixe sont respectées. C'est à dire : Pour tout couple de règles $Z \Rightarrow \beta$, $X \Rightarrow \alpha Y \beta$, on vérifie que $\neg(Y \doteq X)$, $\neg(Y \leq X)$ et $\neg(Y \dot{\leq} X)$.

Pour ce faire nous utilisons la méthode suivante : Pour chaque règle $Z \Rightarrow \beta$, pour toute autre règle $X \Rightarrow \alpha$ on regarde si on peut matcher β comme suffixe de α . Dans l'affirmative, on identifie le symbole juste avant le suffixe. Nous pouvons a ce moment vérifier la condition décrite expliquée précédemment. Si elle n'est pas vérifiée. le Test échoue, la grammaire n'est pas valide.

3.8 Test de Cycles

Un cycle est definit formellement par tout ensemble de règles de productions donnant $E \xRightarrow{+} \alpha E \beta$. ou α et β sont 'nullables'. Comme en WP il ne peut y avoir de productions vides, on vérifie $\neg(E \xRightarrow{+} E)$. Pour ce faire on crée un graphe directionnel ayant pour noeuds les symboles non terminaux et pour arcs les règles de productions de type $A \Rightarrow B$. On vérifie ensuite l'absence de cycles dans ce graphe via un algorithme adéquat.

3.9 Spécifications des méthodes importantes

```
/**
 *
 * @param rules The rules list
 * @param table The precedence table
```

```

    * @return a list of tuple (triple)
    * that contains the two conflicting rules and
    * the suffix the cause the conflict
    */
    public static List<RulesTuple> checkSuffix(List<Rule> rules,
        Hashtable<Term,Hashtable<Term,String>> table)

    /**
    * Regarde si la grammaire n'a pas de conflits de précédence.
    * Affiche la table des précédence à la sortie standard.
    * @param grammar Une grammaire cohérente :
    * tous les non terminaux ont au moins une règle.
    * @return true si la grammaire est valide, false sinon.
    */
    public static boolean checkPrecedence(List<Rule> grammar)

    /**
    * Met une relation de précédence dans la table de précédence et
    * résout les conflits. Affiche les détails de l'erreur à la sortie
    * standard en cas de conflits. Si le conflit est entre <. ou <.= ou =.
    * celui ci est résolu en insérant un <.=
    *
    * @param table la table de précédence
    * @param X le premier Terme
    * @param Y le second Terme
    * @param rel la relation de précédence ( EQ,LE,GE,LEQ,ERROR,NOTHING)
    * @param rule la règle d'où provient X et Y.
    * @return true si il n'y a pas de conflits, false sinon.
    */
    public static boolean tableSet(Hashtable<Term,Hashtable<Term,String>>
        table, Term X, Term Y, String rel, Rule rule)

    /**
    * Calcule l'ensemble First pour chaque Terme correspondant aux Termes
    * pouvant se trouver à l'extrême gauche de celui ci.
    * @param grammar la grammaire
    * @return une Hashtable qui fait correspondre à chaque Terme son set First.
    */
    public static Hashtable<Term,Set<Term>> FirstSet(List<Rule> grammar)

    /**
    * Calcule la table de précédence WP et si celle ci contient des conflits.
    * En cas de conflits, ceux ci sont affichés à la sortie standard.
    * @param grammar la grammaire
    * @param table une Hashtable à deux dimensions dont 1
    * es clefs sont tous les couples
    * de termes existant dans grammar.
    * Tous les éléments de table sont initialisés
    * à NOTHING.

```

```

    * @return true si il n'y a pas de conflits dans la table, false sinon.
    */
    public static boolean precTable(List<Rule> grammar,
    Hashtable<Term,Hashtable<Term,String>> table)

    /**
    * Vérifie que la liste ne contient pas d'expansions vides,
    * en cherchant les termes 'lambda' dans tous les termes de toutes
    * les règles.
    * @param grammar la grammaire
    * @return true si la grammaire ne contient pas de terme 'lambda',
    * false sinon.
    */
    public static boolean checkLambda(List<Rule> grammar)

```

3.10 Test du vérificateur

Nous avons testé notre vérificateur de grammaire avec les grammaires fournies sur icampus pour finalement tester avec notre grammaire. Ici je ne montrerai que le test final pour notre grammaire.

3.11 Premier Test

```

<A> ::= <A> 'a'
<A> ::= <B>
<B> ::= 'a'
<B> ::= <A> <B>

Check conflit suffix :
-----
A   A
<.
-----
B   A
<=
-----
conflit avec a:true
A ::= A:false a:true
B ::= a:true

conflit avec B:false
B ::= A:false B:false
A ::= B:false

```

Validity grammar : false
Ce test concorde bien avec l'exemple donné

```

Grammaire non WP :
règle 1 : B --> a
règle 2 : A --> A a
A <. B
Grammaire non WP :
règle 1 : A --> B
règle 2 : B --> A B
A <. A

```

3.12 Second Test

:

```
<E> ::= <T>
<E> ::= '+' <T>
<E> ::= <E> '*' <T>
<T> ::= <F>
<T> ::= <T> '*' <F>
<F> ::= 'x'
<F> ::= '(' <E> ')'
```

C'est bien une grammaire WP :

```
Precedence Table
| (  ( )  | *  | +  | T  | E  | F  | x  |
=====
(  | < . |   |   | < . | < . | <= | < . | < . |
-----
)  |   | .> | .> | .> |   |   |   |   |
-----
*  | < . |   |   |   |   |   | . = | < . |
-----
+  | < . |   |   |   |   | <= |   | < . | < . |
-----
T  |   | .> | . = | .> |   |   |   |   |
-----
E  |   | . = |   |   |   |   |   |   |
-----
F  |   | .> | .> | .> |   |   |   |   |
-----
x  |   | .> | .> | .> |   |   |   |   |
-----

No conflicts in table
Validity precedence : true
Check conflit suffix :
Validity grammar : true
```

3.13 Troisième Test

Dernière grammaire qui est normalement fausse :

```
E --> T
E --> + T
E --> T + E
T --> F
T --> F * T
F --> x
F --> ( E )
```

```
Precedence Table
| (  ( )  | *  | +  | T  | E  | F  | x  |
=====
(  | < . |   |   | < . | < . | . = | < . | < . |
-----
)  |   | .> | .> | .> |   |   |   |   |
-----
*  | < . |   |   |   |   | . = |   | < . | < . |
-----
+  | < . |   |   | < . | <= | . = | < . | < . |
-----
T  |   | .> |   | . = |   |   |   |   |
-----
E  |   | . = |   |   |   |   |   |   |
-----
F  |   | .> | . = | .> |   |   |   |   |
-----
x  |   | .> | .> | .> |   |   |   |   |
-----

No conflicts in table
Validity precedence : true
Check conflit suffix :
-----
E   +
. =
-----
conflit avec T:false
```

```
E ::= +:true T:false  
E ::= T:false  
Validity grammar : false
```


Chapitre 4

Analyse syntaxique

4.1 Grammaire WP du langage

```
<l0> ::= <l_block> ' ) ' | ' l_id '  
<l_block> ::= ' ( ' <l_list>  
<l_list> ::= <l0> | <l0> <l_list>
```

Étant donné les nombreux déboires et retournement de situations pour rendre notre syntaxe WP nous avons décidé d'utiliser une autre approche qui consiste à seulement différencier les niveaux d'imbrication de parenthèses et les 'identifiants' qui comprennent les identifiants, mais aussi les mots réservés et les nombres. Ceux ci sont désignés par '*l_id*' dans la grammaire, mais en pratique ces symboles gardent leur type donné par l'analyseur lexical. Le gros du travail est donc délégué aux étapes ultérieures.

4.2 Problèmes rencontrés

Le premier problème venait du flou entourant la définition de cycle. Nous avons travaillé sur une mauvaise définition beaucoup trop restrictive qui nous a amené à différencier chaque niveau d'imbrication. Comme cela n'était pas possible avec la syntaxe de base nous avons utilisé la syntaxe minimaliste présentée ci-dessus. Lorsque nous nous sommes rendu compte de notre erreur, nous avons continué dans notre approche. En effet la validation de la syntaxe n'est pas spécialement plus compliquée au niveau de l'arbre syntaxique.

Le second problème est un conflit de précedence au niveau des parenthèses qui a été résolu en séparant les paires de parenthèses en deux règles de production séparées.

4.3 Code de l'analyseur syntaxique

Voici le code de l'analyseur syntaxique, la méthode principale est `parse`, qui fait appel aux sous méthodes *shift* et *reduce*. L'invariant de parse est le suivant : Soit `S` la stack : et `L` la liste de symboles non encore lus :

- soit `S` contient une poignée à son sommet.
- soit `S` ne contient pas de poignée et `L` est non vide.
- soit `S` contient l'unique symbole start et `L` est vide et la syntaxe est parsée.
- soit le programme n'est pas valide.

`parse()` passe de l'un de ces cas à l'autre avec `shift` et `reduce` pour consommer `L` et arriver au symbole de départ, ou à une erreur auquel cas le programme s'arrête.

```
/*
 * @pre : ~
 * @post: A terminal is read from the lexical parser and put on
 * the top of the stack, and returns true.
 * If there is no terminal left to read, it will do nothing and return
 * false
 */
public boolean shift(){
    if(next == null && lexParser.hasNext()){
        System.out.println("coucou");
        stack.push(lexParser.next());
        if(lexParser.hasNext()){
            next = lexParser.next();
        }
        return true;
    }else if(next != null){
        stack.push(next);
        next = lexParser.next();
        return true;
    }
    return false;
}
/*
 * @pre : There is a symbol on the stack.
 * @post : ~
 * @returns :
 * Returns the precedence relation between the symbol with index
 * i and i+1 on the stack. If i is equal to the stack size -1 it
 * returns the precedence relation with the symbol that will be
 * placed on the stack on the next shift.
 */
public String prec(int i){ ... }
/*
 * @pre : ~
 * @post : Prints the stack and the next element.
 */
public void printStack(){ ... }
/*
 * @pre: ~
 * @post: ~
 * @return: true if there is only the start symbol left on the stack, and
 * nothing left to read on the lexical parser.
 */
public boolean done(){ ... }

/*
 * @pre : There is a symbol on the stack.
 * @post :
 * Tries to match the stop of the stack with the right side of a rule.
 * It will try to match <.= ... > handles first. If it cannot match
 * the first <. ... > handle found, it will stop and return false.
 * If it finds a match the handle is removed from the stack, put as
 * the child of a new Term corresponding to the left hand of the matching
 * rule, and that Term is put on the top of the stack.
 * @return : returns true if could reduce, false if it couldn't.
 */
public boolean reduce(){
    int i = stack.size() -1; /* beginning of the handle */
    boolean hard = false; /*it has tried to match a < ... > handle */
}
```

```

boolean match = true;
while(i >= 0){
    int matchsize = stack.size()-i;
    if( prec(i-1).equals(CheckPrecedence.LE)
    || prec(i-1).equals(CheckPrecedence.LEQ)){
        if(prec(i-1).equals(CheckPrecedence.LE)){
            hard = true;
        }
        for(Rule r:grammar){
            for(CatList c:r.getOrList()){ /*we iterate over rules */
                List<Term> L = c.getTermList();
                if(L.size() != matchsize){
                    continue;
                }
                int j = 0;
                match = true;
                while(j < matchsize){ /*matching the handle with the rule*/
                    if(!L.get(j).equals(stack.get(i+j))){
                        match = false;
                        break;
                    }
                    j++;
                }
                if(!match){
                    continue;
                }
                Term R = new TermImpl(r.getLeftSide().getType(),false);
                j = 0;
                while(j < matchsize){ /*removing from the stack and adding to the child list */
                    R.getChildList().add(stack.remove(i));
                    j++;
                }
                stack.push(R);
                return true;
            }
        }
    }
    if(hard){
        return false;
    }
    i--;
}
return false;
}
/*
 * @pre : the object has been correctly initialized with a lexical
 * parser and a precedence table.
 * @post : Tries to parse the input, if successful puts the result in tree and
 * returns true. returns false and prints an error message otherwise.
 */
public boolean parse(){
    while(shift()){
        while(prec(stack.size()).equals(CheckPrecedence.GE)){
            if(!reduce()){
                if (done()){
                    tree = stack.get(0);
                    return true;
                }
                System.out.println("Syntax Error : Could not reduce");
                printStack();
                return false;
            }
        }
        if(done()){
            tree = stack.get(0);
            return true;
        }
    }
}
if (done()){
    tree = stack.get(0);
    return true;
}else{
    System.out.println("Syntax Error : Program too long");
    return false;
}
}
}

```

4.4 Traduction du programme en code interne

4.4.1 Création de l'arbre syntaxique du programme

L'arbre syntaxique est constitué de *Term* afin qu'il puisse être généré directement par l'analyseur syntaxique. La méthode `getChildList()` de la classe *Term* renvoie la liste des *Term* enfants.

Le code de l'analyseur syntaxique prend en entrée un flux *Term* qui sont tous terminaux. L'analyseur syntaxique n'a besoin que des méthodes définies dans l'interface *Term* pour construire l'arbre. Voici cette interface :

```
public interface Term {
    /**
     *
     * @return true if the term is a terminal term
     */
    public boolean isTerminal();

    /**
     *
     * @return Le type du term pour l'analyseur syntaxique.
     */
    public String getType();

    /**
     *
     * @return la valeur du term, c'est à dire la chaîne de caractère
     *         parsée par l'analyseur lexical.
     *         Si le term n'est pas terminal, il n'a pas de valeur
     */
    public String getValue();

    /**
     * Modifie la valeur du term
     * @param v la nouvelle valeur du term
     * @return this
     */
    public Term setValue(String v);

    /**
     * Renvoie la liste des enfants du terme, cette liste n'est pas vide que
     * si le term n'est pas terminal
     * @return
     */
    public List<Term> getChildList();

    /**
     * Imprime l'arbre qui est représenté par le term
     * Indent définit le niveau d'indentation, lorsqu'on imprime
     * l'arbre entier le point de départ est 0
     * @param indent
     */
    void printTree(int indent);
}
```

Une fois le code déjà donné dans le chapitre 6 exécuté, l'arbre (le *Term*) passe dans le *treeOrganiser*.

La première chose à faire avec l'arbre généré par l'arbre brut est de mettre tout ce qui est au même niveau de parenthèses au même niveau dans l'arbre. Pour cela on le parcourt et on fusionne récursivement tous les *l_blocks* et les *l_lists* dans leurs parents. Comme les *Term* gardent en mémoire le type donné à l'analyse syntaxique, les terminaux récupèrent automatiquement le bon type.

Voici la spécification de la seule méthode public du *TreeOrganiser* :




FIG. 4.1 – Schema simplifié de la restructuration de l'arbre

```

/**
 * Contracte l'arbre sortit par l'analyseur syntaxique.
 * Tout les l_list et l_block sont
 * retiré, à la fin il ne reste que des l0 qui sont
 * soit des terminaux ou des listes de l0.
 * @return L'arbre représenté sous la forme d'un lexicalTerm
 */
public LexicalTerm contract()

```

La structure de donnée LexicalTerm est très similaire à Term, elle implémente l'interface on a rajouté une méthode getLexicalTerm qui est le type donnée par le parser lexical. Ces types ont été listé dans la partie sur l'analyseur lexical. Une fois l'arbre mis en forme et les types des termes réels révélés (pas ceux juste présent pour construire l'arbre), on passe à la traduction.

4.5 traduction

Il y a trois grande famille de traduction, la traduction des définitions de méthode, la traduction des instructions et la traduction des conditions. La traduction des définitions de méthode est assez facile car on sait qu'un programme en Happy est une liste de méthode. Donc les enfants de la racine

sont les méthodes, l'enfant 0 de l'enfant est le mot clé, l'enfant 1 sont les paramètres et l'enfants 2 est la suite d'instruction.

```
/**
 * Point de départ de l'exploration de l'arbre.
 * t est un term qui une liste de term qui est en accord avec la définition
 * des méthodes ou des fonctions.
 * Si t n'est pas conforme aux définitions, une erreur de syntaxe est
 * lancée et le programme
 * se termine
 * @param t
 * @return la Cmethod
 */
private Cmethod analyseMethod(LexicalTerm t) {
```

Une fois les arguments et le nom de la méthode récupéré il faut commencé à ajouté toutes les instructions à au corps de la méthode. La méthode privée `addBody` crée une liste vide qui accueillera toutes les instructions de la méthode. Cette table permet de placer en premier les instructions qui se trouvent au fond de l'arbre pour gérer correctement les appels imbriqués.

Les instructions dans le langage Happy sont toutes des expressions, c'est-à-dire qu'elle renvoie une valeur. Contrairement dans la traduction cela ce fait par l'assignation d'une valeur (qui dépend du type d'instruction) variable anonyme qui sera renvoyé à la méthode appelante. Cette méthode appelante utilisateur la variable si elle en a besoin.

Voici le code de la méthode *addOutput*

```
/**
 * Ajoute l'instruction output à la liste des instructions, les expressions
 * imbriquée dans cette instruction seront ajouter avant l'exécution de celle-ci
 * @param child la liste des arguments de l'instruction write,
 * size == 2, l'élément 0 est le term write
 * et le seconde une expression
 * @param table la table des variables local
 * @param body la table contenant les instructions de la méthode
 * @param counter le compteur des variables anonymes
 * @return la variable qui contient la valeur de retour de l'instruction
 */
private Cvar addOutput(List<LexicalTerm> child, MethodTable table,
List<Ccmd> body, AnonymousCounter counter) {
//si l'expression est terminal on peut la traiter tout de suite
if(child.get(1).isTerminal()) {
Cvar v1 = null;
if(WordIdentifier.isRexpr(child.get(1))) {
Crexpr r = WordIdentifier.getRexpr(child.get(1));
String name = counter.getAnonymousName();
table.addLocal(name);
v1 = new Cvar(name);
body.add(new Cass(v1,r ));
}
else if(child.get(1).getLexicalTerm().equals("id")) {
v1 = new Cvar(child.get(1).getValue());
table.addLocal(child.get(1).getValue());
}
//erreur terminal mais ni une expression ni un id
```

```

    else {
        System.out.println("Expected number id or expr");
        System.out.println("in write");
        System.exit(15);
    }
    Clexpr[] expr = {v1};
    Coutput out = new Coutput(expr);
    body.add(out);
    return v1;
}
//sinon on explore la commande et on récupère la valeur de l'expression
else {
    Cvar v1 = exploreCmd(child.get(1), table, body, counter);
    Clexpr[] expr = {v1};
    Coutput out = new Coutput(expr);
    body.add(out);
    return v1;
}
}
}

```

Dans ce code on voit bien les deux cas de figure : les arguments de l'instruction sont des terminaux ou non. On voit aussi l'utilisation des variables anonymes grâce à la classe AnonymousCounter qui a comme seul objectif de fournir des noms différents pour chaque variable anonyme d'une méthode.

Voici un petit de l'exécution de la méthode addOutput :

Considérons le code Happy suivant :

```

(write
  (set a
    (+ 7 8)
  )
)

```

sera traduit en:

```

A_0 = 7 ; //l'expression 7 est assignée à A_0
A_1 = 8 ; //idem pour 8
A_2 = (A_0 + A_1) ; //l'expression (+ A_0 A_1) est assignée à A_2
a = A_2 ; //assignation de l'expression (+ A_0 A_1) à a en passant par A_2
A_3 = a ; //set renvoie la variable qu'il vient d'assigner
write(A_3) ;

```

Les conditions fonctionnent un peu comme l'exploration des commandes, mais ici il faut distinguer deux types de conditions. Les conditions avec un opérateur logique (and, or, not) et les conditions avec un opérateur de relation. Les premières ne peuvent avoir comme argument que des conditions tandis que les secondes ne peuvent avoir comme argument que des expressions.

Voici un exemple de condition avec un opérateur logique :

```

/**
 * Cette fonction renvoie une condition de type and.
 * @param child la liste des Term qui forme la conditions,
 *   size == 3 et les éléments 1 et 2 doivent être des conditions
 * @param table la table des variables locales
 * @param body la table contenant la liste des commandes du corps de la méthode
 * @param counter le compteur de variable anonyme
 * @return La condition and.
 */

```

```

private Ccond getAnd(List<LexicalTerm> child, MethodTable table,
List<Ccmd> body, AnonymousCounter counter) {
    if(child.get(1).isTerminal() || child.get(2).isTerminal()) {
        System.out.println("Syntax error at AND, expected condition");
        System.exit(16);
    }
    return new Cand(getCond(child.get(1), table, body, counter),
        getCond(child.get(2), table, body, counter));
}

```

Ici encore on voit les appels récursif à getCond (en effet l'appel de getAnd vient uniquement d'un appel à getCond). Les conditions avec un opérateur de relation fonctionnent exactement comme les instructions. L'implémentation avec les expressions imbriquées dans les relations pose un petit soucis. Les expressions sont placées au dessus du if ou du while et leur résultat sont placés dans une variable anonyme. Cette variable est ensuite utilisée dans la condition. Dans un if ceci ne pose pas de problème mais dans un while on risque d'avoir très vite une boucle infinie car les expressions ne sont plus réévaluées une fois dans le while. (Il faudrait donc aussi rajouter les instructions imbriquées à la fin du while mais l'implémentation dans sa forme actuelle ne permet pas de le faire facilement). C'est pourquoi le code suivant est vivement déconseillé

```

[code qui écrit les chiffres de 1 à 10]
(
    (fun (main) (
        (set i 0)
        (while (<= (set i (+ i 1)) 10) (
            (write i)
        ))
    ))
)

```

[La sortie est tout autre => une infinité de 1]

[Voici le code conseillé]

```

(
    (fun (main) (
        (set i 1)
        (while (<= i 10) (
            (write i)
            (set i (+ i 1))
        ))
    ))
)

```

[Ce code va effectivement sortir les chiffres de 1 à 10]

4.6 traduction du code en code interne

Ici nous avons utilisé la méthode Cprog.translate(). Qui nous a posé quelque problème lorsque qu'il y avait dans la traduction en code structuré. En effet les erreurs renvoyées ne sont pas des plus claires.

Voici le premier programme de la démo qui fait la somme de 1 à n.

```

(
    [Commentaire]
    (fun (main) (
        (set i 0)
        (while (<= i 10)
            (
                (write (sum i))
            )
        )
    ))
)

```



```

    (set i (+ i 1))
  ))
))

(fun (sum n) (
  (if (= n 0)
    (return 0)
  )
  (return (+ n (sum (- n 1)))))
))
)

```

Traduction en code structuré

```

main()
{
  i = 0 ;
  A_0 = i ;
  A_1 = 10 ;
  while (i <= A_1)
  {
    A_2 = sum(i) ;
    write(A_2) ;
    A_3 = 1 ;
    A_4 = (i + A_3) ;
    i = A_4 ;
    A_5 = i ;
    A_6 = 0 ;
  }
  A_7 = 0 ;
  A_8 = 0 ;
}

```

```

sum(n)
{
  A_0 = 0 ;
  if (n == A_0)
  {
    A_1 = 0 ;
    return (A_1) ;
  }
  A_2 = 0 ;
  A_3 = 1 ;
  A_4 = (n - A_3) ;
  A_5 = sum(A_4) ;
  A_6 = (n + A_5) ;
  return (A_6) ;
  A_7 = 0 ;
}

```

Traduction en code interne

```

method main()
{ lab16
  [ lab16 : i#1 := 0 ; go to lab15]
  [ lab15 : A_0#2 := i#1 ; go to lab14]
  [ lab14 : A_1#3 := 10 ; go to lab5]
  [ lab5 : if A_1#3 < i#1 then go to lab3 else go to lab4]
  [ lab3 : A_7#9 := 0 ; go to lab2]
  [ lab2 : A_8#10 := 0 ; go to lab1]
  [ lab4 : skip ; go to lab13]
  [ lab13 : #11 := i#1 ; go to lab12]
  [ lab12 : A_2#4 := sum(#11) ; go to lab11]
  [ lab11 : write(A_2#4) ; go to lab10]
  [ lab10 : A_3#5 := 1 ; go to lab9]
  [ lab9 : A_4#6 := i#1 + A_3#5 ; go to lab8]
  [ lab8 : i#1 := A_4#6 ; go to lab7]
  [ lab7 : A_5#7 := i#1 ; go to lab6]
  [ lab6 : A_6#8 := 0 ; go to lab5]
} lab1 result#0
end of method main.

method sum(n)
{ lab29
  [ lab29 : A_0#2 := 0 ; go to lab28]
  [ lab28 : if n#1 == A_0#2 then go to lab27 else go to lab25]
  [ lab27 : A_1#3 := 0 ; go to lab26]
  [ lab26 : result#0 := A_1#3 ; go to lab17]
  [ lab25 : A_2#4 := 0 ; go to lab24]
  [ lab24 : A_3#5 := 1 ; go to lab23]
  [ lab23 : A_4#6 := n#1 - A_3#5 ; go to lab22]

```

```

[ lab22 : #10 := A_4#6 ; go to lab21]
[ lab21 : A_5#7 := sum(#10) ; go to lab20]
[ lab20 : A_6#8 := n#1 + A_5#7 ; go to lab19]
[ lab19 : result#0 := A_6#8 ; go to lab17]
} lab17 result#0
end of method sum.

```

Et finalement l'exécution

```

0
1
3
6
10
15
21
28
36
45
55

```

Chapitre 5

Interpréteur

5.1 Implémentation

Nous avons choisit d'implémenter l'interpréteur en écrivant de nouvelles méthodes dans les classes fournies. Cela permet d'éviter d'écrire un long programme pour interpréter et d'éviter de nombreux cast. Notre système utilise les classes abstraites fournies pour imposer une interface commune au type qui en dérive.

Toutes les commandes (méthode, statement etc) doivent implémenter *execute*. Toutes les Expressions doivent implémenter *getVal*. Et tous les désigneurs doivent implémenter *assign*.

En plus de cela nous utilisons deux types de données pour représenter les objets et toutes les valeurs. Une valeur contient un type et en fonction du type un entier ou une référence. (Nous utilisons le terme entier car nous utilisons la classe `BigInteger` pour stocker les entiers et leur taille n'est limitée que par la mémoire de la machine)

Nous avons défini 4 types de variables conformément à la sémantique. Les entiers, les références qui pointent vers un objet dans le store ou null, les erreurs et le type inconnu qui permet aux membres des objets d'être initialisés avec soit une référence soit un int car dans tous les autres cas il est interdit de changer le type d'une variable. (Sauf que cette interdiction posant problème lors de la traduction en code interne, le code interne utilise plusieurs fois la même variable anonyme et les assigne à des objets très différents parfois, nous l'avons retiré)

Nous avons défini deux types de données le store et l'environnement. Pour la pile nous utilisons implicitement la pile de java grâce aux appels récurrents d'*execute*. L'environnement est un tableau de valeur (class `Val`) et le store est un `TreeMap` qui associe un int (la référence) à un objet (class `Object` dans `slip.internal`). L'environnement et le store sont passés à toutes les méthodes abstraites *execute*, *getVal*, *assign* afin que toutes les classes puissent consulter et modifier le store et leur environnement.

Nous utilisons un TreeMap dans le store pour garantir l'ordre dans les clés lorsque nous itérons, cela permet de rendre le Garbage Collector plus efficace. Nous parlerons du Garbage Collector plus tard.

Dans l'environnement nous avons aussi rajouté une variable level qui ne peut pas être modifiée (car quand on change de niveau de méthode on change aussi d'environnement) qui indique à quel niveau de méthode on se trouve afin d'empêcher d'accéder à des champs out of scope ou à des méthodes out of scope.

Nous avons dans la sémantique défini un langage très stricte qui ne tolère pas de division par zéro, ni de changement de type pour une variable. Toutes ces actions débouchent sur une erreur et l'arrêt du programme.

5.1.1 Changement de l'implémentation

Execute recursif entre les statement Lors de la première implémentation, nous avons implémenté les exécutions des instructions récursivement, c'est à dire que chaque instruction appelle la méthode exécute de la suivante. Tout se passe bien quand il n'y pas beaucoup d'instruction et même lorsqu'il y a en beaucoup réellement écrite (200 write à la suite par exemple) car dans ce cas là le java faisait une récursion terminal mais lorsqu'on faisait un while qui exécutait 200 fois une commande, ce n'était plus récursif terminal du coup et donc dépassement de la pile d'exécution. Nous avons donc modifié l'implémentation, maintenant les méthodes exécute la ligne renvoyée par la méthode execute de l'instruction, c'est comme si on parcourait une liste d'instruction, on ne s'enfonce plus dans la pile d'exécution.

Gestion de l'overflow La meilleure façon de gérer les overflow lors des calcul sur les int est de ne pas en avoir, pour ne pas en avoir nous avons simplement remplacer les int par des BigInteger, bien cela nous fait perdre un peu de performance. Malheureusement nous n'avons pas pu remplacer le int dans la classe I, car celui-ci est donnée par la traduction en code interne. On ne peut donc pas écrire des entier plus grande que 2^{32} mais le résultat des calcul (et leur affichage) peut dépasser et n'est limité que par la taille de la mémoire. (on ne peut donc pas vraiment parler d'entier)

Changement de l'environnement Pour gagner en rapidité nous avons remplacé la HashMap de l'environnement par un simple tableau de valeur, ce tableau est initialisé à l'appel de la méthode, et il peut l'être parce que nous connaissons à l'avance le nombre de variable allouée dans la méthode.

Un autre changement qui aurait éviter tout les ennuis d'implémentation du Garbage Collector et d'implémentation du store, est pour la référence au lieu de stocker un int qui donnera un objet dans la HashMap du store, stocker directement la référence de l'objet java et utiliser le store de java

directement et ainsi utiliser directement le Garbage Collector de java. Cette modification sera pour la prochaine version du langage.

Gestion des erreurs Dans la première implémentation, l'interpréteur donnait juste la nature de l'erreur et s'arrêtait. Maintenant nous avons créé une classe exception `SlipError` qui possède une pile et un message. l'erreur est transmise de l'endroit où elle s'est déclenchée jusqu'à la méthode `execute()` du programme et à chaque étape, l'interpréteur rajoute un élément sur la pile. En plus de l'erreur on a maintenant l'endroit exact de l'erreur et toute la pile d'exécution. Le seul défaut est que l'endroit exact correspond à l'endroit en code interne.

Garbage Collector Nous avons tenté d'implémenter un garbage collector qui s'exécutait toute les 200 millisecondes. Il parcourait toute la liste des environnements de la pile d'exécution et il plaçait dans un set toutes les références qu'il trouvait et si il n'avait pas encore rencontré la référence il explorait récursivement les références contenu dans l'objet. A la fin de cette étape le garbage collector avait une liste ordonnée de toutes les références encore accessible. Il suffisait donc de parcourir le store (qui lui aussi était ordonné) et de supprimer toutes les références qui n'ont pas été trouvées par l'étape 1. Les premiers tests étaient concluants mais lors de l'exécution du programme `Qsort` avec une liste de 7000 éléments nous avons eu des références nulle alors qu'elles ne devaient pas l'être. Le Garbage Collector était trop gourmand. Nous l'avons donc désactivé et là nous nous sommes rendu compte que `fibonnaci` récursif prenait deux fois moins de temps à s'exécuter. Et finalement avec la dernière amélioration de l'environnement proposé le Garbage Collector devient totalement obsolète.

5.1.2 Lien avec la sémantique opérationnelle

5.1.3 Test

Nous allons reprendre les tests du rapport précédent et y ajouter quelques tests d'icampus qui ne figuraient pas la première fois.

Chapitre 6

Mode d'emploi du compilateur

La version exécutable du compilateur et interpréteur Happy se trouve dans le jar exécutable *happy.jar*. Il prend 2 arguments obligatoire : la grammaire au format BNF et le programme en langage Happy. On peut rajouter *check* à la fin pour vérifier la grammaire en plus. Pour faire fonctionner les programmes Happy, il faut passer la grammaire *temp.bnf*. Pour vérifier n'importe quelle grammaire WP, il faut indiquer la grammaire un fichier programme bidon et enfin check. exemple :

```
java -jar happy.jar temp.bnf programme1.happy
java -jar happy.jar temp.bnf programme1.happy check
```

L'interpréteur sort les informations suivantes dans cet ordre, si le check de la grammaire est demandé, le résultat des tests et la table de précedence. Ensuite l'arbre sortit par le parser syntaxique après sa restructuration, ensuite la traduction de l'arbre en SLIP et puis (mais il semble que les retour à la ligne ne soit pas conforme ce qui donne des résultats étranges à la sortie dans le shell) la représentation en code interne SLIP. Et finalement la sortie du programme interprété.

6.1 Les erreurs

Lorsqu'une erreur arrive dans n'importe quelle partie du compilateur l'erreur est affichée (avec plus ou moins de précision) et il s'arrête ensuite.

6.2 Les erreurs du vérificateur

Le vérificateur de grammaire WP évalue les critères les uns après les autres et s'arrête dès qu'un critère n'est pas respecté, en indiquant à la

console l'endroit où cela coince de manière assez explicite.

6.3 Les erreurs du parser lexical

Il ne vérifie que deux choses. A la fin de l'analyse si il n'y a pas le même nombre de parenthèse ouvrantes que fermantes, l'erreur *Unexpected end*. Il est aussi capable de vérifier si à tout moment il y a trop de parenthèse fermantes, le message est dès lors très explicite : *Too much)* .

6.4 Les erreurs de l'analyseur syntaxique

L'analyseur syntaxique signale trois erreurs. Lorsque deux termes ne peuvent se retrouver côte à côte, lorsqu'il n'arrive pas à trouver une règle pour réduire.

Et lorsqu'il a lu tout les caractères, si il reste plus d'un élément dans la pile une erreur est aussi renvoyé.

6.5 Les erreurs du traducteur

Les erreurs que renvoient le traducteur sont d'ordre sémantique. Le programme est valide syntaxiquement mais comme notre grammaire permet beaucoup de chose, Il faut remettre les choses en places avec le traducteur. Les erreurs sont du type : quelquechose est attendu dans ce type d'expr et là c'est pas le cas. exemple : `textitExpected id after a set`

6.6 Les erreurs de l'interpréteur

L'interpréteur reporte les erreurs d'exécutions telles que la division par 0, l'appel à méthode inconnue etc... Les erreurs sont clairement identifiées dans le code interne structurée et reporté jusqu'au dessus de la pile d'exécution. Cela permet de retracer l'erreur sans trop de difficulté. Voici un exemple :

```
Error divide by 0
in Cexpr a#1 / b#2
at Ass A_0#3 := a#1 / b#2
at CmdStmt [ lab9 : A_0#3 := a#1 / b#2 ; go to lab8]
at divide/-1
at Call divide
at CmdStmt [ lab2 : A_0#3 := divide(#4, #5) ; go to lab1]
at main/-1
```